

Architecture U-Net

Introduction



Image Classification



Object Detection







Image Segmentation




Introduction



Brain MRI (T1CE)



Ground Truth Segmentation



Predicted Segmentation



image



unet output




prediction




ground truth

Architecture U-Net

Input
image



C, H, W — Que représentent ces 3 lettres ?



Layer (type)	Output Shape	Param #
input_3 (InputLayer)	(None, 96, 128, 3)	0
sequential (Sequential)	(None, 96, 128, 3)	0
conv2d_20 (Conv2D)	(None, 48, 64, 64)	1792
conv2d_21 (Conv2D)	(None, 48, 64, 64)	36928
conv2d_22 (Conv2D)	(None, 24, 32, 128)	73856
conv2d_23 (Conv2D)	(None, 24, 32, 128)	147584
conv2d_24 (Conv2D)	(None, 12, 16, 256)	295168
conv2d_25 (Conv2D)	(None, 12, 16, 256)	590880

[C × H × W]

forme du tenseur

H Height — la hauteur

C'est simplement le nombre de lignes de l'image (ou de la feature map). Quand l'encodeur applique un MaxPool, H est divisé par 2. Le décodeur le remultiplie par 2 à chaque étape jusqu'à retrouver la taille d'origine.

W Width — la largeur

C'est le nombre de colonnes. H et W évoluent toujours ensemble : ils sont divisés par 2 à chaque descente, et multipliés par 2 à chaque remontée. Pour une image carrée, H = W à chaque niveau.

C Channels — les canaux

C'est le nombre de "filtres" actifs. Au départ c'est 1 (image en niveaux de gris) ou 3 (RGB). Après chaque bloc de convolution, C double : le réseau crée de plus en plus de détecteurs de features. C'est vous qui choisissez la valeur de départ (64 dans U-Net de base).

L'Encodeur

Conv 3×3 + ReLU



Conv 3×3 + ReLU

→ les deux forment un bloc convolutif



MaxPool 2×2

→ résolution ÷ 2, canaux × 2

× 4 niveaux

64 → 128 → 256 → 512 canaux

Ce que fait l'encodeur

L'encodeur est la partie gauche du U. Son rôle est d'analyser l'image en profondeur, couche après couche, pour comprendre ce qu'elle contient.


À chaque niveau, deux convolutions extraient des features de plus en plus abstraites : d'abord des bords et textures simples, puis des formes, puis des structures complexes. Après ces deux convolutions, un MaxPool réduit la résolution de moitié, on perd de la précision spatiale, mais on gagne en abstraction.

C'est un compromis voulu : le réseau sacrifie le "où exactement" pour mieux comprendre le "quoi". Les skip connections sont précisément là pour compenser cette perte lors de la remontée.




Analogie : c'est comme regarder une image en prenant du recul. On voit moins les détails mais on comprend mieux la scène globale.

Architecture U-Net



Le Bottleneck : La représentation latente

Encodeur → compression



Ce que représente le bottleneck

Le bottleneck est le point le plus étroit du réseau. C'est là que toute l'information de l'image est résumée dans une représentation très compacte, appelée représentation latente (ou latent layer).


À ce stade, la résolution spatiale est minimale : on a perdu tous les détails fins de position. Mais le nombre de canaux est au maximum : le réseau dispose de 1024 "têtes" qui analysent l'image sous 1024 angles différents.

Le bottleneck sait donc répondre à la question "qu'est-ce que c'est ?" mais plus vraiment à "où exactement ?". C'est le décodeur, aidé des skip connections, qui se chargera de répondre à la deuxième question.



C'est l'équivalent d'une description verbale : "il y a une tumeur ronde en haut à gauche", sans pouvoir montrer exactement ses contours.

Le Bottleneck : La représentation latente



Le Décodeur

UpConv 2×2

résolution × 2, canaux ÷ 2



Concat avec skip

fusion encodeur + décodeur



Conv 3×3 + ReLU



Conv 3×3 + ReLU

→ raffiner la représentation fusionnée

× 4 niveaux


Ce que fait le décodeur

Le décodeur est la partie droite du U. Son travail est de reconstruire une carte de segmentation à la même résolution que l'image d'entrée.


À chaque niveau, il commence par une UpConv qui double la résolution. Puis il concatène le résultat avec la feature map correspondante de l'encodeur — c'est la skip connection. Cette fusion est la clé : elle combine le contexte global venant du bottleneck avec les détails spatiaux fins sauvegardés par l'encodeur. Deux convolutions raffinent ensuite cette représentation fusionnée.

À la toute fin, une convolution 1×1 transforme les 64 canaux en autant de canaux qu'il y a de classes à prédire. Chaque pixel reçoit un score par classe, et le gagnant détermine la segmentation.

Le Décodeur



Les Skip Connections



Pourquoi les skip connections existent

Le MaxPool de l'encodeur est nécessaire pour comprendre l'image globalement, mais il a un effet de bord : il détruit l'information sur la position précise des pixels. Après quatre MaxPool successifs, le réseau ne sait plus exactement où se trouvent les bords qu'il a détectés au départ.

Les skip connections règlent ce problème élégamment. Avant chaque MaxPool, la feature map est copiée et mise de côté. Quand le décodeur remonte au même niveau de résolution, cette copie lui est transmise directement.

Le décodeur se retrouve donc avec deux sources d'information en même temps : ce qui vient du bas (le contexte global, la sémantique) et ce qui vient du côté (les détails spatiaux fins). La concaténation fusionne ces deux sources, et les convolutions apprennent à les combiner intelligemment.

C'est comme réviser un examen avec deux ressources : vos notes détaillées (skip) et votre compréhension globale du cours (bottleneck).

U-Net en un coup d'œil

Encodeur

64 → 128 → 256 → 512 ch
H, W ÷2 à chaque niveau

Analyse l'image en profondeur.
Extrait des features de plus en plus abstraites. Sauvegarde les détails spatiaux via les skip connections.

Bottleneck

1024 canaux
Résolution minimale

Représentation latente : sait QUOI est dans l'image mais plus OÙ exactement. C'est le résumé le plus compact de l'image.

Décodeur

512 → 256 → 128 → 64 ch
H, W ×2 à chaque niveau

Reconstruit la carte de segmentation. Remonte en résolution grâce aux UpConv et récupère les détails fins via les skip connections.

Skip Connections

Mêmes C, H, W
que l'encodeur correspondant

Transmettent les détails spatiaux de l'encodeur au décodeur. Permettent des frontières nettes en combinant contexte global et détails locaux.

U-Net = Encodeur + Bottleneck + Décodeur + Skip Connections

|Sources

[U-Net clearly explained | Image Segmentation with AI](#)

[U-Net: Convolutional Networks for Biomedical Image Segmentation](#)

[A Mathematical Explanation of UNet](#)