

Les auto-encodeurs variationnels (VAE)

ModIA - 31/03/2026


Brice Vergnou, Paul Rohel

Sommaire

1. Les auto-encodeurs (AE)
2. Variétés et espace latent
3. Auto-encoders variationnels (VAE)
4. Cadre probabiliste
5. Application des VAE en recherche
6. Sources

Les auto-encodeurs (AE)


Apprentissage non supervisé : entrée comme vérité terrain



Source : [1] Cours Deep Learning (INSA)

- **Encodeur** : projette l'entrée dans un espace latent de dimension réduite ($\Leftrightarrow$ ACP si activations linéaires)
- **Décodeur** : reconstruit une approximation de l'entrée à partir de cette représentation latente

Variétés et espace latent



Source : [2] Structures de l'espace latent (Abad, 2026)




Source : [3] Kingma & Welling (2013)

But : décrire, dans l'espace latent, la variété sur laquelle vivent les données


i.e trouver un sous-espace sur lequel on a une haute probabilité de rencontrer les données d'apprentissage

Variétés et espace latent

Espace latent idéalement de dimension semblable à celle de la variété des données.



Source : [4] Formation FIDLE (CNRS)



Intérêt :

- Structuration des données (clustering, séparation des facteurs de variation) dans un espace de plus faible dimension
- Génération de nouvelles données par échantillonnage d'un point latent puis décodage.

Auto-encoders variationnels (VAE)

But : créer un **AE** dont l'apprentissage est **régularisé** avant d'éviter l'**overfitting** et s'assurer que l'espace latent ait de **bonnes propriétés permettant le processus génératif**

Les 2 traits de la régularisation


Continuité :

2 points proches dans l'espace latent donnent des résultats décodés très similaires

Complétude :

Un point échantillonné n'importe où dans l'espace latent donne un contenu significatif une fois décodé

L'intérêt de la loi normale



Fonction de coût

$$\text{Total Loss} = \underbrace{L_{\text{reconstruction}}}_{\text{Erreur de reconstruction}} + \underbrace{D_{\text{KL}}}_{\text{Divergence Kullback-Leiber (KL)}}$$

Erreur de reconstruction :

Différence input/output
L'objectif est de conserver
l'information

Divergence Kullback-Leiber (KL) :

Mesure la "distance" entre la distribution
prédite par l'encodeur et le prior $\mathcal{N}(0, I)$. Force
les distributions latentes à se chevaucher, ce
qui garantit la continuité.

$$D_{\text{KL}} = \frac{1}{2} \sum_{j=1}^J (1 + \ln(\sigma_j^2) - \mu_j^2 - \sigma_j^2)$$

Divergence Kullback-Leiber (KL)

$$D_{\text{KL}} = \frac{1}{2} \sum_{j=1}^J (1 + \underbrace{\ln(\sigma_j^2)}_{\text{red}} - \underbrace{\sigma_j^2}_{\text{green}} - \underbrace{\mu_j^2}_{\text{blue}})$$

Empêche σ de s'annuler car le résultat exploserait, ce qui reviendrait à un AE

$x \mapsto \ln x - x$ atteint son extremum en (1,1)


Minimisé en 0

Objectif : avoir $\mathcal{N}(0, 1)$

Astuce de reparamétrage

Problème : Impossible de faire la rétropropagation car l'échantillonnage est un processus aléatoire. Or, il est impossible de calculer la dérivée d'une opération stochastique

Solution : Plutôt que de simuler z de façon stochastique, on externalise l'aléatoire dans une variable externe ϵ . L'opération est alors dérivable car c'est une simple addition de variables déterministes.



◊ : Deterministic node
● : Random node

[Kingma, 2013]
[Bengio, 2013]
[Kingma and Welling 2014]
[Rezende et al 2014]

Source : [7] "reparameterization trick" (Kingma, NIPS 2015)

Cadre probabiliste

- Distribution *a priori* sur l'espace latent : $p(z) \equiv N(0, I)$
- Décodeur $\equiv$ loi conditionnelle de x sachant z : $x = f_\theta(z) + \varepsilon$ avec $\varepsilon \sim N(0, \sigma^2 I)$

$$p_\theta(x|z) \equiv N(f_\theta(z), \sigma^2 I)$$

- Encodeur $\equiv$ loi conditionnelle de z sachant x :

$$p(z|x) \sim q_\phi(z|x) \equiv N(\mu_\phi(x), \sigma_\phi(x)^2 I)$$

- Fonction objectif à maximiser :

$$L(x) = E_{q_\phi(z|x)} [\log(p_\theta(x|z))] - KL(q_\phi(z|x) || p(z))$$


mesure la **qualité de reconstruction** de x (~MSE en pratique)

- contraint $q(z|x)$ à rester proche de $p(z)$
- **structure l'espace latent** pour la génération


Applications : inversion du modèle radiatif PROSAIL

- PROSAIL : modèle physique déterministe
variables biophysiques $\rightarrow$ réflectance (VIS-IR)
- Objectif : inverser le modèle par réseau de neurones
réflectance (VIS-IR) $\rightarrow$ variables biophysiques
- Difficultés :
 - ! peu de données labellisées, besoin de données distribuées réalistement
 - ! problème **non injectif**

Idée : Utiliser un VAE **contraint physiquement** pour apprendre une représentation latente permettant d'inférer des variables biophysiques cohérentes avec la réflectance observée.



Source : [5] Thèse Zérah (2024)



- Donnée reconstruite : acquisition satellite (Sentinel-2)
 - Espace latent : représentation probabiliste des variables biophysiques, apprise via $q(z | y)$
- $$y \rightarrow z \rightarrow x \rightarrow y'$$
- Décodeur déterministe et différentiable : PROSAIL + simulateur de la réponse spectrale des capteurs

Applications : Recalage d'image satellites

DIFFÉRENTES BANDES

01-CONTEXTE

Capteur Visible Short Wave InfraRed (SWIR)




Figure 3a : Bande B02 à 485nm (bleu). Figure 3b : Bande B03 à 555 nm (vert). Figure 3c : Bande B04 à 650 nm (rouge).




Figure 3d : Bande B05 à 860 nm (végétation). Figure 3e : Bande B06 à 1610 nm (effet d'humidité).

Capteur Thermal InfraRed (TIR)




Figure 4a : Bande B10 à 10,3 μm . Figure 4b : Bande B11 à 11,5 μm .

Figure 4 : Images issues du capteur TIR avec le satellite Landsat 8 sur une zone autour de Montpellier en niveau de gris.

Recalage pour la mission TRISHNA

- Différents instruments = pixels non alignés.

Explication du recalage (extrait de ma présentation)

Applications : Recalage d'image satellites

MISE EN ŒUVRE DU RECALAGE


01-CONTEXTE

Etape 1 :

- Calcul de similarité pour tous les pixels de I, J.
- Recherche du pixel correspondant.
- Décalage/disparité (décalage ligne et colonne).



Image I



Patch centré en un pixel

Image J



Fenêtre de recherche

Patch centré en un pixel de la
fenêtre de recherche

Figure 6 : Calcul de similarité par formalisme par patches avec en noir le pixel de référence, en rouge la fenêtre de recherche et en vert les patches de la fenêtre de recherche.

Etape 2 :

- Recalage de J sur I par application d'une transformation géométrique.

Explication du recalage (extrait de ma présentation)

Applications : Recalage d'image satellites




Figure 7 : [1] Architecture MCCNN




Figure 8 : [2] Architecture VAE

- On applique MCCNN entre le patch de base et tous ceux de la zone de recherche
- Un VAE possède un espace latent théoriquement continu
- MCCNN est une boîte noire, VAE permet de voir ce qu'on reconstruit
- On a plus de liberté sur l'apprentissage
- On peut par la suite se servir de l'encodeur pour remplacer la partie convolutionnelle du MCCNN

Explication du recalage (extrait de ma présentation)

Sources

- [1] Chevallier, J., Autoencoder (AE) & Variational Autoencoders (VAE), Cours High-Dimensional Deep Learning, INSA Toulouse / ENSEEIHT, 2024-2025.
- [2] Abad, A. G., « Latent Space Structures in Deep Learning Models », LinkedIn Pulse, 2026.
- [3] Kingma, D. P. & Welling, M., Auto-Encoding Variational Bayes, arXiv:1312.6114 [stat.ML], 2013.
- [4] FIDLE (CNRS), Variational Autoencoder (VAE): principles and latent space, Vidéo de formation, disponible sur fidle.cnrs.fr / YouTube, consulté en 2026.
- [5] Zérah, Y., Physics-based deep representation learning of vegetation using optical satellite image time series, Thèse de doctorat, CESBIO, HAL Id: tel-04807662, 2024.
- [6] Joshi, Manoj & Pant, Dibakar & Karn, Rupesh & Heikkonen, Jukka & Kanth, Rajeev. (2022). Meta-Learning, Fast Adaptation, and Latent Representation for Head Pose Estimation. Proceedings of the XXth Conference of Open Innovations Association FRUCT. 31. 10.23919/FRUCT54823.2022.9770932.
- [7] Diederik (Durk) Kingma, Max Welling, Variational Auto-Encoders and Extensions, NIPS Workshop (2015)